Exer-Colesterol

M Perez-Casany

11/11/2021

L'Objectiu d'aquest exercici és estudiar com es comporta el Colesterol com a funció d'altres variables.

Farem una regressió lineal simple i una múltiple.

Establim el directori de treball i carreguem els paquets

```
setwd("~/Desktop/Docencia/PiE2/Curs21-22")
library(survival)
library(Formula)
library(colorspace)
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 3.5.2
```

```
library(carData)
library(Hmisc)
```

```
## Loading required package: lattice
```

```
##
## Attaching package: 'Hmisc'
```

```
## The following objects are masked from 'package:base':
##
##     format.pval, units
```

```
library(car)
library(tables)
library(lattice)
library(grid)
library(gridExtra)
library(MASS)
library(latticeExtra)
```

```
## Loading required package: RColorBrewer
```

```
##
## Attaching package: 'latticeExtra'
```

```
## The following object is masked from 'package:ggplot2':
##
##     layer
```

```
library(RColorBrewer)
library(multcompView)
library(mvtnorm)
```

```
## Warning: package 'mvtnorm' was built under R version 3.5.2
```

```
library(TH.data)
```

```
## Warning: package 'TH.data' was built under R version 3.5.2
```

```
##
## Attaching package: 'TH.data'
```

```
## The following object is masked from 'package:MASS':
##
##     geyser
```

LLegim les dades i fem estadística descriptiva

```
dadescol<-read.csv2("../Dades2/COL.csv")
head(dadescol)
```

```
##    A   H    W     C
## 1 19 174 79.9 189.5
## 2 15 151 64.5 197.5
## 3 13 133 52.0 170.5
## 4 19 173 75.5 180.5
## 5 17 163 74.0 216.5
## 6 13 135 54.9 173.5
```

```
dim(dadescol)
```

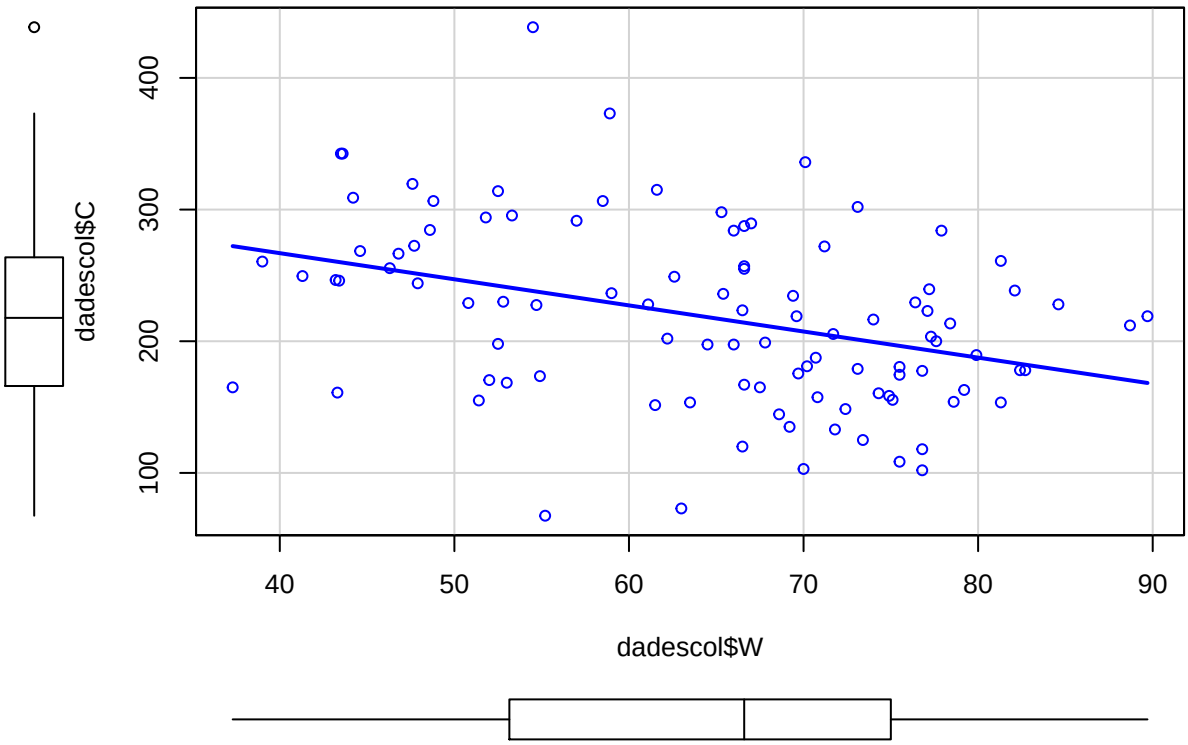
```
## [1] 100   4
```

A 100 joves se'ls hi ha mesurat el nivell de colesterol juntament amb l'edat, l'alçada i el pes.

Sembla que la primera variables que pot afectar el colesterol és el pes, per tant començarem fent un model de regressió lineal simple que tingui el pes com a explicativa.

Prèviament visualitzem les dades amb el que s'anomena "diagrama de dispersió" o "scatterplot"

```
scatterplot(dadescol$W,dadescol$C, smooth=F)
```



Contràriament al que cabia esperar, sembla que el colesterol és més baix per a persones de pes mel elevat. Mirant els boxplots veiem que hi ha una persona amb un valor de colesterol molt més elevat que la resta.

Ajustem el primer model: Regressió lineal simple

```
model1<-lm(dadescol$C~dadescol$W )
summary(model1)
```

```
##
## Call:
## lm(formula = dadescol$C ~ dadescol$W)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -169.24  -39.81   -4.49   47.19  200.37
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 346.2251    33.1983   10.43  < 2e-16 ***
## dadescol$W   -1.9835     0.5046   -3.93 0.000158 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 63.55 on 98 degrees of freedom
## Multiple R-squared:  0.1362, Adjusted R-squared:  0.1274
## F-statistic: 15.45 on 1 and 98 DF,  p-value: 0.0001581
```

De la sortida del "summary" veiem que:

1) Ambdós coeficients son estadísticament diferents de zero.

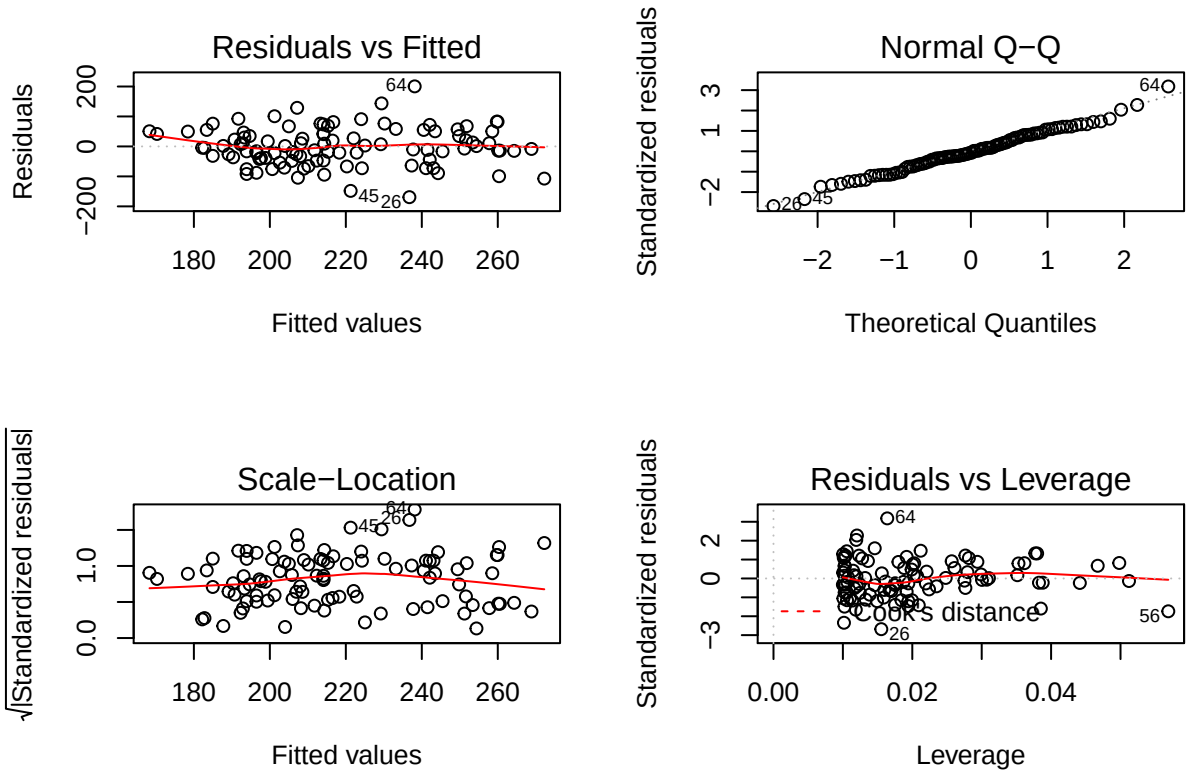
2) Sembla que hi ha residus força grans (tenint en compte la magnitut de la variable).

3) El coeficient de determinació (R^2) és molt petit, indicant que queda molta variabilitat en la variable colesterol que no explica el pes de les persones. El pes només explica un 13% de la variabilitat entre els nivells de colesterol.

4) Basant-nos en el test F, veiem que el model de regressió lineal simple és millor que el model nul, per tant que hi ha una part de la variabilitat del colesterol que ve explicada perquè els individus tenen diferent pes.

Mirem si es compleixen les hipòtesis del model lineal (fem servir el quatre plots que fa l'R per defecte quan li especifiques un model)

```
oldpar <- par( mfrow=c(2,2))
plot(model1,ask=F)
```




```
par(oldpar)
```

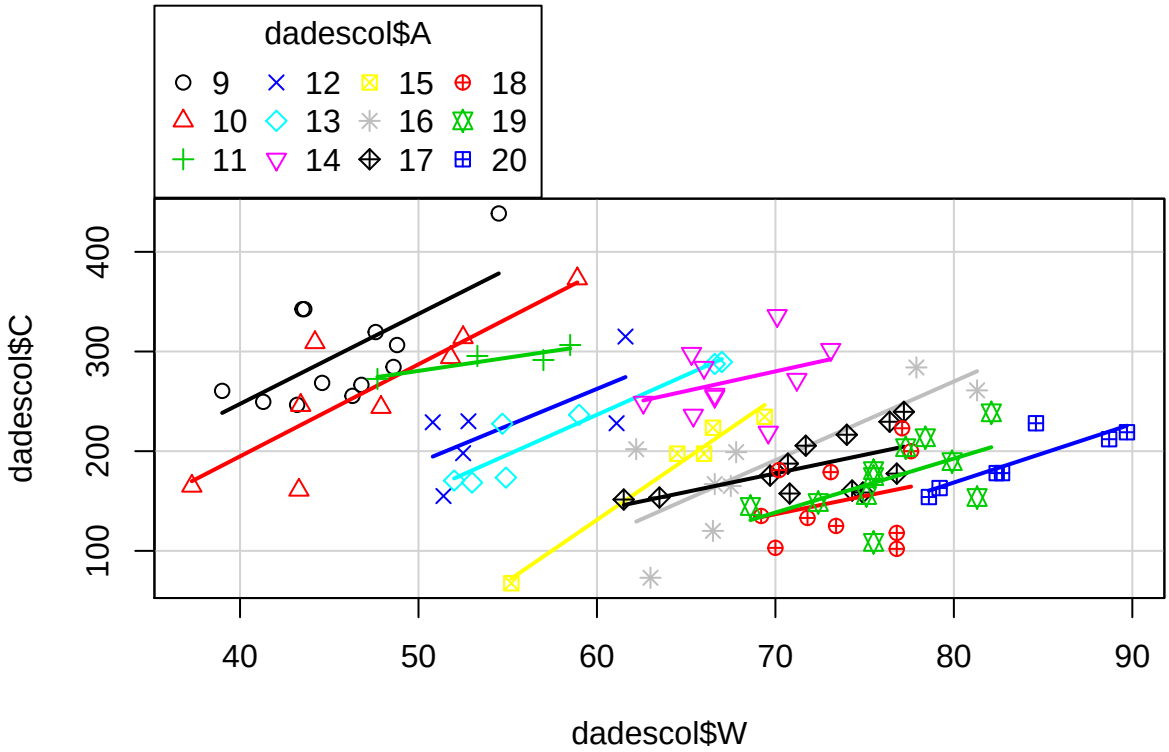
D'aquests plots podem dir que la hipòtesi d'homocedasticitat no es veu massa clara. La Normalitat dels residus és força clara i no veiem valors amb valors de "leverage" grans ni distància de Cook grans.

Dibuixem els residus estandaritzats juntament amb les linees horitzontals a -2, 0 i 2 per veure quants d'ells cauen fora de l'interval $(-2, 2)$ (si el model és apropiat, n'hi ha d'haver aproximadament un 5%)

Veiem que hi ha 5 residus fora de l'interval esmentat que és exactament un 5%.

Portem a terme a continuació un plot de dispersió del colesterol com a funció del pes, però separant els individus per grups d'edat.

```
sp(dadescol$C~dadescol$W|dadescol$A,smooth=F,col=1:20, data=dadescol)
```

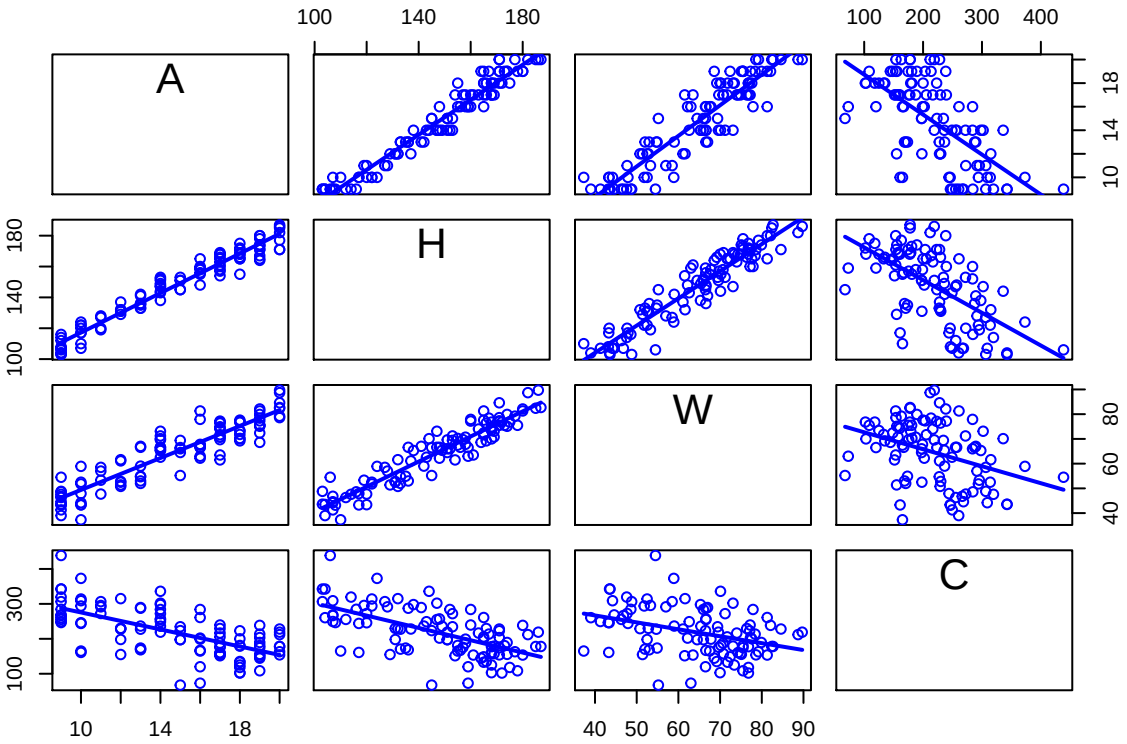


Ara les coses canvien, si agrupem els individus per edats, sí que veiem que el nivell de colesterol semble més alt per les persones de més pes. El com augmenta dependrà de l'edat. Per tant doncs, cal tenir en compte com a mínim també la variable edat en el model.

Ajustem diversos models de Regressió lineal múltiple

Fem una mica de visualització de les dades

```
scatterplotMatrix(dadescol, diagonal=F, smooth=F)
```



Veiem que pes i alçada estan linealment relacionades, i probablement només en podrem posar una perquè sino tindrem problemes de multicolinealitat.

Ajustem el model amb totes les explicatives que tenim

```
model2<-lm(dadescol$C~dadescol$H+dadescol$W+dadescol$A)
summary(model2)
```

```
##
## Call:
## lm(formula = dadescol$C ~ dadescol$H + dadescol$W + dadescol$A)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -74.608 -22.137   1.888  21.156  65.410
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 490.9978    35.0517  14.008  < 2e-16 ***
## dadescol$H   -5.0989     0.7227  -7.055 2.68e-10 ***
## dadescol$W   10.3773     0.7365  14.090  < 2e-16 ***
## dadescol$A  -13.0195     3.8530  -3.379  0.00105 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.11 on 96 degrees of freedom
## Multiple R-squared:  0.8101, Adjusted R-squared:  0.8041
## F-statistic: 136.5 on 3 and 96 DF,  p-value: < 2.2e-16
```

El model ara:

1) Ha passat a explicar el 80% de la variabilitat que hi ha en la variable colesterol. Si mirem el R^2_{ad} veiem que és superior a l'obtingut en el model1 i, per tant, paga la pena modelar amb més paràmetres.

2) Mirant les estimacions dels paràmetres veiem que l'alçada i el pes son todes dues estadísticament significatives perquè els seus coeficients son estadísticament diferents de zero. Encara que estigui linealment relaciondes, cadascuna explica una part de la variabilitat del colesterol. A l'augmentat el pes una unitat (mantenint les altres variables iguals) augmenta el nivell de colesterol en 10.37 unitats. A l'ugmentar l'alçada una unitat (mantenint les altres variables constants), disminueix el pes en 5.09 unitats.

3) A l'augmentar l'edat de la persona, mantenint l'alçada i el pes constants, el nivell de colesterol baixa en 13 unitats.

4) L'estimació de la variància, i.e. una magnitut de l'error de les nostres prediccions és $\hat{\sigma}^2 = (30.11)^2$.

5) Observeu que en aquest model no estem permetent que el pendent de la recta que ens modela el nivell de colesterol en funció de l'edat varii en funció de l'edat. Si volguessim que canvies hauriem d'afegir el terme associat a la interacció

6) Rebutgem la hipòtesi nul.la del test òmnibus, per tant el nostre model és millor que el nul.

Printem la taula anova

```
anova(model2)
```

```
## Analysis of Variance Table
##
## Response: dadescol$C
##             Df Sum Sq Mean Sq F value    Pr(>F)
## dadescol$H   1 171564  171564 189.244 < 2.2e-16 ***
## dadescol$W   1 189273  189273 208.778 < 2.2e-16 ***
## dadescol$A   1  10351   10351  11.418  0.001052 **
## Residuals   96  87031     907
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Aquí veiem quina part de la variabilitat total és explicada per a cadascúna de les variables. Atès que tenen els mateixos graus de llibertat, pode, dir que la que captura més variabilitat és elpes, després l'alçada i finalment l'edat.

Calculem els VIF ("variance inflation factors")

```
vif(model2)
```

```
## dadescol$H dadescol$W dadescol$A
##  31.695499   9.489406  20.904776
```

clarament surten alts, perquè les explicatives estan linealment relacionades. Si en suprimim una però, perderem bondat d'ajust perquè els coeficients de les tres variables son estadísticament diferents de zero.

Per tal de millorar el model, en aquest cas, enlloc de considerar la variable ples, el que cal considerar el que s'"anomena excés de pes".

Se sap que el pes d'una persona "normal" en funció de la seva alçada ve determinada per

$$W^* = -10 + 0.5 * H$$

A partir d'aquí definirem la variable exces de pes com

$$EW = W - W^*$$

, i modelarem el colesteron en funció de la variable EW enlloc de la variable pes.

```
dadescol$EW<-dadescol$W-(-10+0.5*dadescol$H)
model3<-lm(dadescol$C~dadescol$H+dadescol$EW+dadescol$A)
summary(model3)
```

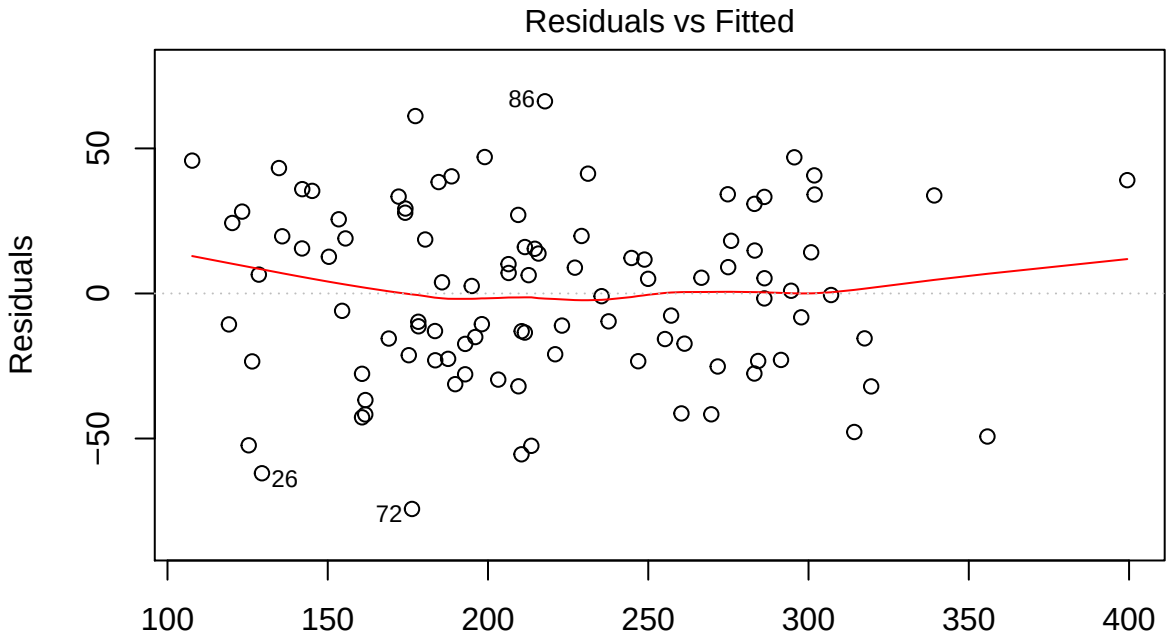
```
##
## Call:
## lm(formula = dadescol$C ~ dadescol$H + dadescol$EW + dadescol$A)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -74.608 -22.137   1.888  21.156  65.410
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 387.22473   33.69605  11.492  < 2e-16 ***
## dadescol$H    0.08972    0.58736   0.153  0.87891
## dadescol$EW  10.37731    0.73649  14.090  < 2e-16 ***
## dadescol$A  -13.01948    3.85300  -3.379  0.00105 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.11 on 96 degrees of freedom
## Multiple R-squared:  0.8101, Adjusted R-squared:  0.8041
## F-statistic: 136.5 on 3 and 96 DF,  p-value: < 2.2e-16
```

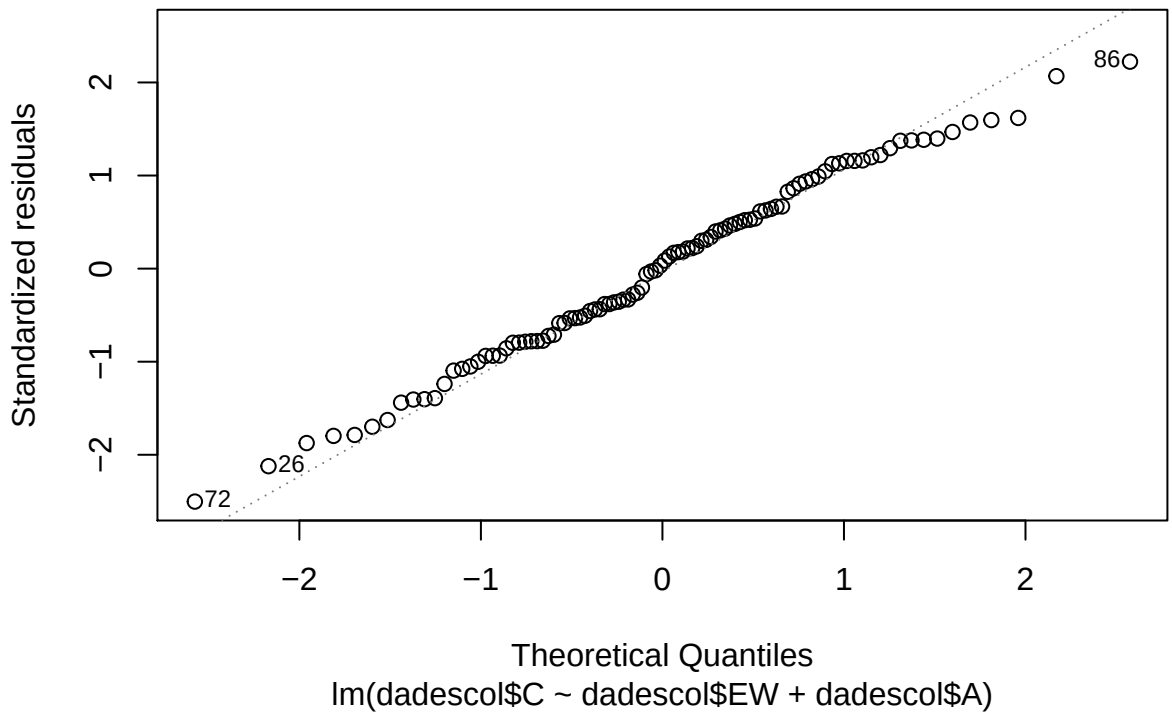
Ara veiem que introduint l'excés de pes l'alçada deixa de ser significativa, per tant la treiem

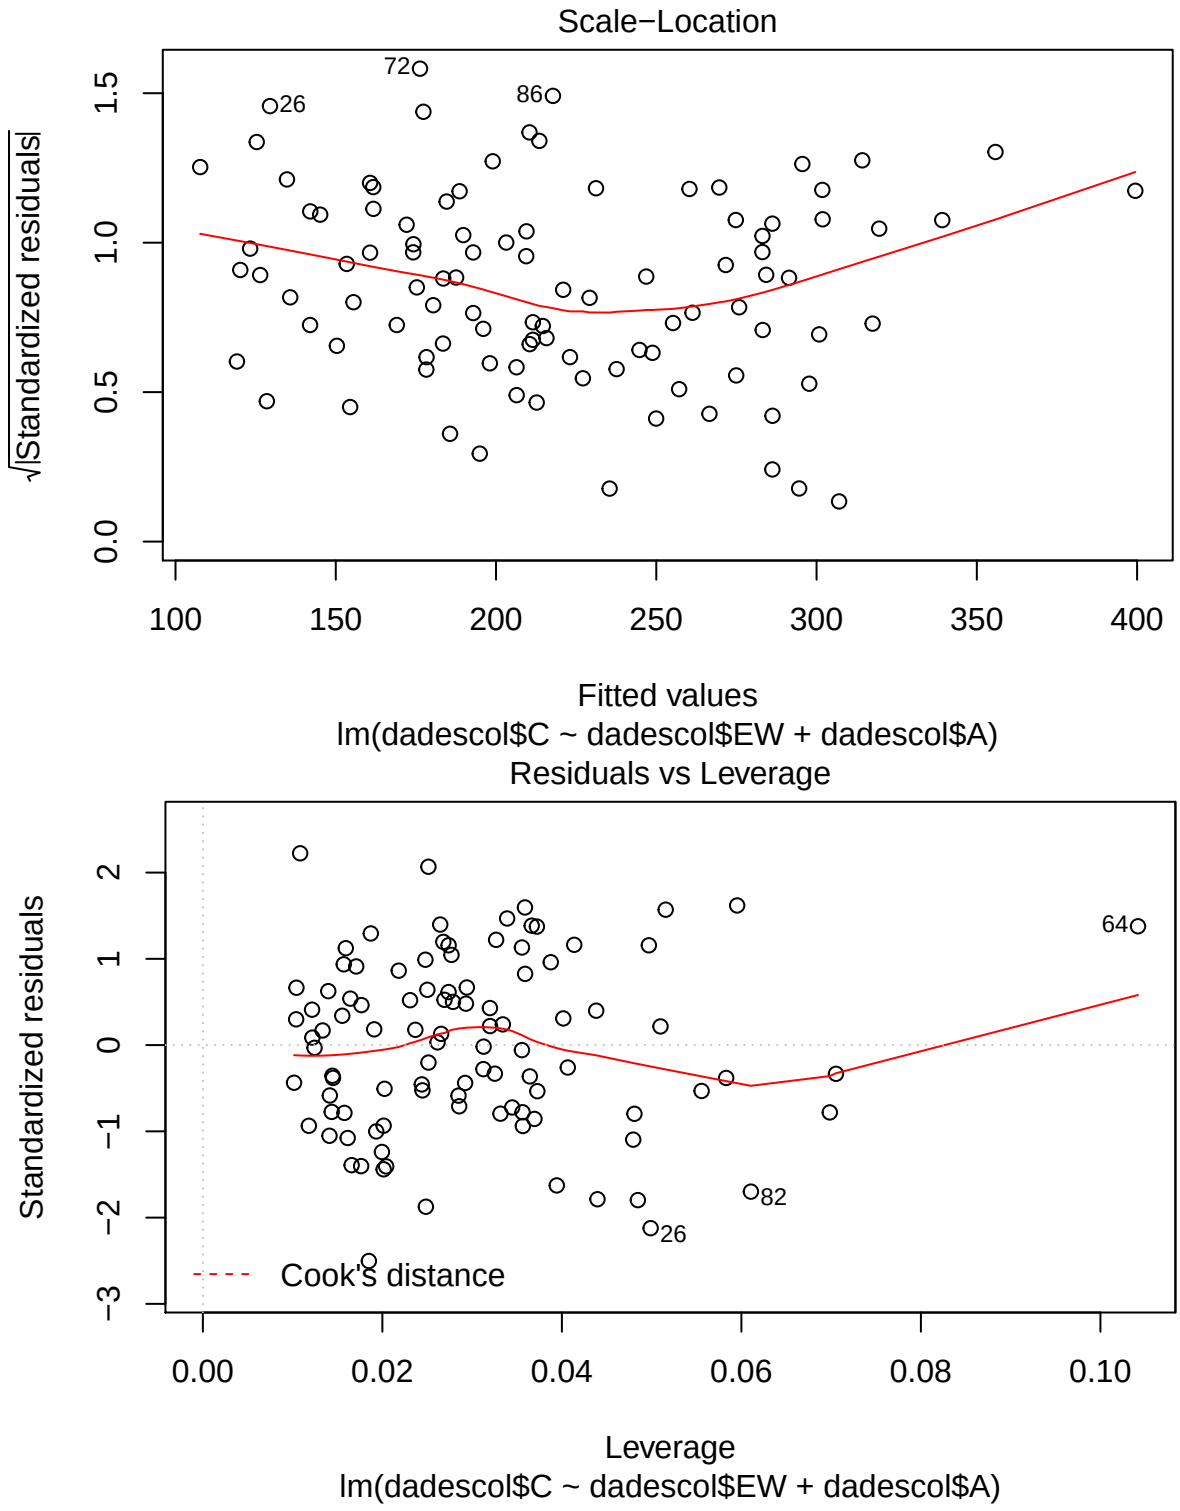
```
model4<-lm(dadescol$C~dadescol$EW+dadescol$A)
summary(model4)
```

```
##
## Call:
## lm(formula = dadescol$C ~ dadescol$EW + dadescol$A)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -74.286 -22.638   1.755  20.935  66.244
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 391.9885    12.6975   30.87   <2e-16 ***
## dadescol$EW  10.3882     0.7294   14.24   <2e-16 ***
## dadescol$A  -12.4452     0.8387  -14.84   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 29.96 on 97 degrees of freedom
## Multiple R-squared:   0.81,  Adjusted R-squared:  0.8061
## F-statistic: 206.8 on 2 and 97 DF,  p-value: < 2.2e-16
```

```
plot(model4, ask=F)
```


Residuals vs Fitted
Residuals
Fitted values
lm(dadescol$C ~ dadescol$EW + dadescol$A)
86
26
72
50
0
−50
100
150
200
250
300
350
400


Normal Q−Q
Standardized residuals
Theoretical Quantiles
lm(dadescol$C ~ dadescol$EW + dadescol$A)
86
26
72
2
1
0
−1
−2




```
vif(model4)
```

```
## dadescol$EW  dadescol$A
##    1.000527    1.000527
```

No veiem evidències de que les hipòtesis del model lineal no es compleixin, per tant es dona com a bon model el model4. Observis ara que no tenim multicolinealitat ja que tots els VIF surten petits. Els valors de l'R^2 i

de l'error estàndard pràcticament son els mateixos que abans.